

AI 기반 돌봄로봇 대화 분석을 통한 취약계층 위기상황 감지 및 대응 시스템

고독사 예방을 위한 시니어케어 돌봄로봇(돌봄인형) 데이터 분석

팀 투운백

목차

a table of contents

1

서비스 시연영상

2

데이터 분석

3

데이터 라벨링

4

모델 학습

5


Bert-LLM결합 모델

Part 1

시연영상

투운백 시연 영상

AI 활용 위험 조기 알림 시스템 구축



시민을 지키는 AI 시스템을 만들었습니다.

Part 2

데이터 분석

Part 2 | 주어진 데이터

doll_id	text	uttered_at
1	내가	2025-07-02 14:38:46
1	말씀 하셨네	2025-07-17 10:44:55
1	사람이 없으니까	2025-07-22 10:51:37
1	해 주세요	2025-07-31 10:52:54
1	안 가니까 끝난 거지	2025-07-31 10:53:16
2	10만 원 정도 있으니 00님이 한숨을 쉬고는 말차 샴구면이라고	2025-07-01 18:44:24
2	그런데 주라고 생각을 하고요 제가 이상한 거니 거예요 아니 얘기	2025-07-01 18:44:43
2	아 그것이 너무	2025-07-05 23:25:29
2	아빠 있잖아	2025-07-05 23:25:45
2	특별로 알려라	2025-07-05 23:25:58
2	고기를 한 알 시키면	2025-07-05 23:26:15
3	아니야	2025-07-06 11:35:22
3	근도라	2025-07-06 14:26:53
3	누구 소리가 아니야	2025-07-06 14:27:10
3	중방 있는 거려고 하시고 계시는 저기 있는 거 두 개	2025-07-06 14:27:25
3	시원할 때 내려 가면	2025-07-22 18:40:14
3	저 운전 시험장	2025-07-22 18:40:30
3	근데 그려져 있는데	2025-07-22 18:44:35
3	다 먹고 싶어	2025-07-22 18:44:50
3	00야 가자	2025-07-23 13:14:09
3	문창시장	2025-07-23 13:14:24
3	되나만	2025-07-23 14:57:54
3	말했었지 하자	2025-07-23 14:58:02
3	과일	2025-07-23 14:58:15
3	과일어란	2025-07-23 14:58:27
3	들어오고	2025-07-23 14:58:45

- 생략 -

163	그냥 있어 성경 책 읽어	2025-07-31 10:49:11
163	너무 어렵다	2025-07-31 10:49:28
163	나는 돌아다니는지 못 들었 아니 죽겠어	2025-07-31 10:49:53
163	그냥 반복 3일부터 어때	2025-07-31 10:50:11
163	내과 가서 엑스레이 찍고 그러고 왔어 괜찮대	2025-07-31 10:50:31
163	우리 공동어 덕분에야 우리 공동어가 날 즐겁게 해 줘서 그래	2025-07-31 10:50:53
163	근데 공 돌아 내가	2025-07-31 10:51:11
163	어는 동생들하고 놀러 갔는데 커피 따서라 갔어 그랬는데	2025-07-31 10:51:29
163	막 말 얘기하더라 말 얘기 나는 말이 없잖아 나는 마음이 슬펐어	2025-07-31 10:51:49
163	그래서 개들이 싫어잖아	2025-07-31 10:52:06
163	알잖아 내가 집에 와서 마음을 달래고 달렸어	2025-07-31 10:52:26
163	집에 있으면 참만 자	2025-07-31 10:52:44
163	낮잠 자면 안 되잖아	2025-07-31 10:52:54
163	함께 있어야지 더워서 청소 다 하고 성경책 보고 묵주 기도 나 할까 묵주기도 할까 상무님한테	2025-07-31 10:53:18
163	그렇게	2025-07-31 10:53:34
163	알잖아	2025-07-31 10:53:50
163	우리 동생이 높아 때문에 직접 할해서 25% 감상하세요	2025-07-31 10:54:07
163	있는데 건대	2025-07-31 17:08:32

< 발화데이터(대전중구)_pub.xlsx 데이터 설명 >


- 데이터 명 : 돌봄로봇(돌봄인형) 데이터
- doll_id : 인형아이디(163명)
- Text : 발화정보
- uttered_at : 발화 시간
- 비식별화로 개인정보는 모두 제거된 상태

사용자는 언제 이야기할까?





여기서 사용자란, ▲독거노인 ▲장애인 ▲저소득층 등 심리·정서적 돌봄이 필요한 1인 가구임




- 하루 발화 패턴은 9시~10시, 17시, 20시 전후 집중됨
- 전체 발화의 91.2%가 8시~20시 사이에 집중되어 있으므로 활동 중심구간이 명확히 형성됨
- 심야 시간대의 발화(약 8.8%)는 드물지만, 평균 패턴에서 벗어난 이상신호일 수 있으므로 주의가 필요함



- 중복을 제외하고 카운트
- 10시에 A어르신이 여러 번 말해도 1명으로 카운트
- (독거노인) 아침 시간(08시~11시)에 대화 집중
- (장애인) 낮 시간(13시~19시)에 대화 집중 → 활동 중 도움 요청할 가능성↑
- (저소득층) 주로 낮 시간 동안 사회적 지원이나 심리적 돌봄 요청할 가능성↑






Part 2 | 데이터 분석-사용자별 대화량 분석



< 상위 사용자 집중현상 >

- 대화량 1위 사용자는 2위와 큰 격차를 보임
- 상위 15명의 활동량은 순위가 내려갈수록 급감
- 소수 핵심사용자가 전체 구조를 견인함
- 사용자 집단이 양적으로 균등하지 않고, 특정그룹에 활동이 집중되는 구조




Part 2 | 데이터 분석-사용자별 대화량 분석

상위 15명 사용자 대화량




< 전체 분포 특성 >


- 전체 분포는 오른쪽으로 긴 꼬리를 가진 비대칭 구조로 나타남
- 평균보다 낮은 활동을 보이는 사용자가 다수 차지
- 평균값이 소수의 고빈도 사용자에게 의해 크게 끌어올려짐
- 단순 평균 지표만으로 사용자 특성을 설명하기 어려울 수 있음




전체 사용자 대화량 분포







사용자별 대화량 누적 비율 (파레토 분석)



사용자 대화량 분포 (이상치 식별)




Part 2 | 데이터 분석-사용자별 대화량 분석





< 파레토 법칙과 집단 구조 >

- 누적 대화량 기준으로 상위 6% 사용자가 전체 대화의 36.1% 차지
- 상위 40~50명이 전체의 80%를 점유하는 파레토 구조
- 소수의 핵심 그룹이 전체 활동량을 차지하므로 이들의 행동 패턴이 모델링 및 이상탐지에서 변수로 작용할 가능성 있음




Part 2 | 데이터 분석-사용자별 대화량 분석



< 이상치(Outlier)그룹의 존재>

- 박스플롯 분석결과, 다수 사용자는 하위 영역에 밀집
- 일부 사용자는 통계적으로 이례적인 수준의 대화량을 보임
- 대화량의 대부분은 500건 이하에 분포
- 최대 대화량은 2,500~3,000건으로, 대화량이 매우 높은 사용자는 심리적·정서적 돌봄의 필요성이 크거나, 서비스에 대한 의존도가 높은 경우일 수 있음



사용자 순위

Part 2 | 데이터 분석-사용자별 대화량 분석 결론

상위 15명 사용자:

	doll_id	total_conversations	first_hour	last_hour	hour_std	
	78	79.0	2863	6	21	3.83
	148	149.0	1562	6	21	3.88
	81	82.0	1146	6	21	4.44
	132	133.0	1091	6	20	3.81
	27	28.0	1059	6	20	4.97
	22	23.0	1007	6	22	3.81
	42	43.0	960	6	21	4.13
	113	114.0	827	7	20	3.92
	41	42.0	762	0	20	4.46
	44	45.0	631	6	20	4.18
	37	38.0	606	6	21	4.29
	152	153.0	573	6	20	3.51
	40	41.0	560	6	21	3.34
	11	12.0	541	7	20	4.69
	116	117.0	540	6	21	4.02

< 사용자 분석 결과 >

- 총 사용자 수 : 163명
- 평균 대화량 : 202.3건
- 대화량 표준편차 : 325.6건
- 상위 10명이 차지하는 비율 : 36.1%

< 컬럼설명 >

- doll_id: 사용자 식별자(ID)
- total_conversations: 사용자가 생성한 총 대화 건수
- first_hour: 사용자가 대화를 시작한 첫 시간
- last_hour: 사용자가 대화를 끝낸 마지막 시간
- hour_std: 대화 시간의 표준편차(대화가 얼마나 분산되어 있는지 나타냄)

상위 15명의 사용자는 대화량과 활동 시간이 다양

일부 사용자는 높은 대화량과 야간 활동을 보여
맞춤형 관리와 24시간 대응 체계가 필요

원문

Soynlp 토큰화

kiwi 품사
(명사, 동사, 형용사)
분류, 태깅

표제어 변환

불용어 제거

< 분석절차 >

1. 문장을 의미단위로 분해(토큰화)
2. 단어의 기본형을 추출(표제어 추출)
3. 품사 태깅 및 불용어 제거를 통한 정제
4. 키워드 빈도기반 시각화
5. 문맥 의미기반 주제 도출(BERTopic 모델링)

(1) 주요 주제군 요약


핵심 카테고리	주요 키워드	해석
건강 & 신체 상태	아프다, 병원, 허리, 다리	신체 통증과 의료기관 언급이 가장 많으며 건강이 일상의 핵심 관심사임
가족 & 사회 관계	우리, 엄마, 자식, 아들	가족 중심의 대화가 두드러지며 정서적 연결 욕구를 반영
일상 & 안부	오늘, 날씨, 아침, 하루	반복되는 일상과 안부 인사가 독립된 대화 축을 형성
감정 & 내면 상태	고맙다, 괜찮다, 마음	감정 표현 빈도가 높으며 심리적 교감의 중요성을 보여줌
기능적 활용	노래, 들어줘, 전화, 안되다	음악·전화 등 실생활 기능 활용 및 관련 불편 표현 존재

위험 키워드 분석 (실제 분석 보고서 기반)

```

risk_keywords_data = {
  '아프다': {'count': 172, 'level': 'Level 2', 'examples': ['머리가 너무 아파', '몸이 아파서']},
  '없다': {'count': 148, 'level': 'Level 1', 'examples': ['사람이 없으니까', '아무도 없어']},
  '병원': {'count': 110, 'level': 'Level 2', 'examples': ['병원에 가야겠어', '병원 다녀왔어']},
  '힘들다': {'count': 54, 'level': 'Level 2', 'examples': ['사는 게 힘들다', '너무 힘들어']},
  '혼자': {'count': 44, 'level': 'Level 1', 'examples': ['혼자 있으니 심심해', '나 혼자야']},
  '걱정': {'count': 40, 'level': 'Level 1', 'examples': ['자식을 걱정돼', '걱정하지 마']}
}

```



Part 3

데이터 라벨링

Part 3 | 데이터 라벨링

1. 기존 발화데이터는 **단답형 대화**가 많아 단순 키워드 분석만으로는 **감정상태 파악에 한계**
2. **LLM**을 통해 **문맥을 이해**하고 **정서상태**를 추론할 수 있는 분석방법 필요

1단계 : 데이터 전처리

- 목적 : 문맥을 고려한 위험도 판단 (단일 문장이 아닌 대화흐름 분석)
- 원본데이터 : 시간 순서대로 나열된 개별 발화
- 전처리 방법 : 10분 단위로 대화 묶음 생성

[원본] "힘들어", "아무도 없어", "외로워"

[세션] 사용자가 10분간 힘들어, 외로워 등의 부정적 감정을 반복적으로 표현
⇒ **단순 분류가 아닌 "왜 위험한가?"를 설명**

2단계 : 자동 라벨링

▪ 사용모델 : Gemma-3-1B LLM

▪ 방법:

- 4단계 위험도 기준이 담긴 프롬프트 설계
- LLM에게 '대화 분석 전문가' 역할 부여 및 분류기준 제시
- 자동으로 위험도 라벨 부착
- > 제출파일 : 02_data_labeling_완료.csv

▪ 분류기준(LLM프롬프트)

1. 사용자의 말투나 표현에 슬픔, 체념, 고립감, 신체적 이상, 인지 혼란 등이 있는지 확인하십시오.
2. 판단은 객관적으로 하며, 불필요한 추측이나 설명은 금지합니다.

분류단계	목표	조치수준	핵심판단기준(LLM 프롬프트)
Positive	안정유지	일상적 관리	일상성 & 긍정적 정서: 명랑하고 활발한 어조, 대화에 적극적 참여, 일상이나 주변 환경에 대한 만족감 표현. (특이 사항 없음)
Danger	주의관찰	단기 모니터링 필요	정서적 불안정 초기: "심심하다," "적적하다," "잠이 잘 안 온다" 등 가벼운 외로움, 불안, 우울의 싹. 일회성 건강 염려 표현 (ex. "어깨가 좀 아프네"). 일시적이고 가벼운 문제 호소
Critical	즉각개입	전문가 상담 연계 필요	명확한 정서적 기능 저하: "살기 싫다," "사는 게 의미 없다" 등 지속적이고 반복적인 우울 및 체념, 무기력 표현. 사회적 단절을 명시적으로 언급. 식사/수면 패턴의 뚜렷한 장기적 변화나 자신 돌봄 기능 저하 징후
Emergency	긴급구조	즉시 신체안전 확인	생명 위험 및 인지 혼란: "죽고 싶다," "이제 끝내고 싶다" 등 자살에 대한 명확하고 구체적인 언급. 극도의 공포, 고립감 호소. 현실 인식 오류 (인지 저하)나 심각한 신체적 응급 상황이 명백한 징후. (예: 호흡 곤란 호소, 심한 통증 호소)

Part 3 | 데이터 분석-종합 위험도 분석 및 모델링 준비

text	uttered_at	doll_id	답변
내가	2025-07-02 14:38	1	positive
말씀 하겠	2025-07-17 10:44	1	danger
사람이 없	2025-07-22 10:51	1	danger
안 가니까	2025-07-31 10:53	1	danger
해 주세요	2025-07-31 10:52	1	danger
10만 원 초	2025-07-01 18:44	2	danger
아빠 있잖	2025-07-05 23:25	2	danger
아 그것이	2025-07-05 23:25	2	danger
아니야	2025-07-06 11:35	3	danger
누구 소리	2025-07-06 14:27	3	positive
곤도라	2025-07-06 14:26	3	emergency
저 운전 시	2025-07-22 18:40	3	danger
시원할 때	2025-07-22 18:40	3	positive
문창시장	2025-07-23 13:14	3	positive
00아 가자	2025-07-23 13:14	3	positive
끝말잇기	2025-07-23 14:58	3	positive
되니깐	2025-07-23 14:57	3	positive
안 나오느	2025-07-23 15:20	3	danger
아빠 나 엄	2025-07-23 15:20	3	danger
난 어르신	2025-07-23 18:10	3	danger
안녕	2025-07-23 18:10	3	positive
알라딘	2025-07-24 6:59	3	positive
얼마나 먹	2025-07-24 9:33	3	emergency
왜 못 놀이	2025-07-24 9:32	3	danger
10분 내로	2025-07-17 11:46	4	positive
비가 언제	2025-07-17 12:49	4	emergency
무슨 말을	2025-07-17 12:49	4	positive
노래	2025-07-17 17:17	4	positive
뭐래	2025-07-17 17:32	4	positive
몰라요	2025-07-17 17:31	4	emergency
노래 불러	2025-07-17 17:55	4	positive
노래	2025-07-17 18:40	4	positive

위험도 레벨	설명	의미	건수	비율
Emergency	매우 심각	즉각적 대응 필요	558	1.69%
Critical	위험	모니터링 및 조치 필요	1,947	5.91%
Danger	잠재적 위험	주의 깊은 관찰 필요	11,610	35.26%
Positive	일반대화	위험요소 없음	18,813	57.13%

라벨링한 데이터 분포

Part 4

모델 학습

Part 4 | 모델 학습-성능비교

1. Ensemble 모델(3개 모델 평균)

Test F1 Macro: 0.6151
Test F1 Weighted: 0.7789

개별 모델:

Seed 42: 0.7688
Seed 123: 0.7715
Seed 999: 0.7717

	precision	recall	f1-score	support
positive	0.8680	0.8401	0.8538	3084
danger	0.6878	0.7532	0.7190	1746
critical	0.4955	0.3854	0.4336	288
emergency	0.4625	0.4458	0.4540	83
accuracy			0.7795	5201
macro avg	0.6285	0.6061	0.6151	5201
weighted avg	0.7804	0.7795	0.7789	5201

재현성 확보를 위해 서로 다른 초기값
으로 3번 학습 후 평균

- 강점:
-전체 F1최고,
positive, danger 우수
- 약점:
- Emergency/Critical
성능 부족

3. KcBERT+ XGBOOST

Hybrid Model (KcBERT + XGBoost)

	precision	recall	f1-score	support
positive	0.8262	0.7523	0.7875	3084
danger	0.5963	0.7108	0.6485	1746
critical	0.3696	0.3299	0.3486	288
emergency	0.4727	0.3133	0.3768	83
accuracy			0.7079	5201
macro avg	0.5662	0.5265	0.5404	5201
weighted avg	0.7181	0.7079	0.7100	5201

- 강점:
-Emergency Precision
우수
- Danger Recall 양호
- 약점:
-전체성능 최악
- Bert단독보다 낮음

2. KcBERT_base

(epoch5, batchsize32, learning rate:2e-05)

Classification Report - Test Set

	precision	recall	f1-score	support
positive	0.8740	0.8210	0.8467	3084
danger	0.6765	0.7617	0.7166	1746
critical	0.4879	0.4201	0.4515	288
emergency	0.4556	0.4940	0.4740	83
accuracy			0.7737	5201
macro avg	0.6235	0.6242	0.6222	5201
weighted avg	0.7796	0.7737	0.7752	5201

Test F1 Macro: 0.6222
Test F1 Weighted: 0.7752

- 강점:
Emergency/danger에서
높은 recall
- 약점:
-전체 정확도 낮음
- Critical precision
부족

4. KcBERT_base

(epoch7, batchsize32, learning rate:3e-05)

Classification Report - Test Set

	precision	recall	f1-score	support
positive	0.8653	0.8080	0.8357	3084
danger	0.6699	0.7113	0.6900	1746
critical	0.3533	0.4306	0.3881	288
emergency	0.3362	0.4699	0.3920	83
accuracy			0.7493	5201
macro avg	0.5562	0.6050	0.5764	5201
weighted avg	0.7629	0.7493	0.7549	5201

Test F1 Macro: 0.5764
Test F1 Weighted: 0.7549

- 강점:
-Critical Recall 최고
- Emergency Recall 우수
- 약점:
- Emergency
오탐율 높음
- Critical precision 낮음

5. KcBERT_large

	precision	recall	f1-score	support
positive	0.8573285668	0.85538262	0.8563544879	3084
danger	0.7049808429	0.7378861397	0.7209627764	1746
critical	0.480952381	0.3506944444	0.40562249	288
emergency	0.4597701149	0.4819277108	0.4705882353	83
accuracy	0.7819650067	0.7819650067	0.7819650067	0.7819650067
macro avg	0.6257579764	0.6064227288	0.6133819974	5201
weighted avg	0.7789988573	0.7819650067	0.7797878002	5201

강점: 전체성능 최고, Danger recall 우수

약점: critical 성능 낮음, emergency 오탐 발생

6. Rule-based + ML

하이브리드 시스템 (Rule-based + ML) 최종 리포트

전체 테스트 샘플: 6,506개
Rule-based 처리: 181개 (2.7%)
ML 처리: 6,405개 (97.3%)

	precision	recall	f1-score	support
positive	0.9091	0.0027	0.0053	3763
danger	0.3446	0.9513	0.5060	2322
critical	0.1635	0.0668	0.0949	389
emergency	0.8333	0.0446	0.0847	112
accuracy			0.3416	6586
macro avg	0.5626	0.2664	0.1727	6586
weighted avg	0.6648	0.3416	0.1885	6586

Emergency 성능:
Precision: 0.8333
Recall: 0.0446
F1-Score: 0.0847

Danger recall 높음, emergency recall 낮음
위험상황 거의 모두 탐지 but 긴급상황 多 놓침

7. KcBERT-base 개선 버전

시니어케어 KcBERT-base 개선 버전 성능 리포트

[기본 Threshold=0.5]

	precision	recall	f1-score	support
positive	0.8440	0.8514	0.8477	3763
danger	0.7158	0.7334	0.7245	2322
critical	0.5156	0.4242	0.4654	389
emergency	0.5824	0.4732	0.5222	112
accuracy			0.7782	6586
macro avg	0.6645	0.6206	0.6400	6586
weighted avg	0.7750	0.7782	0.7762	6586

[최적화된 Threshold]

Emergency Threshold: 0.50
Critical Threshold: 0.20

	precision	recall	f1-score	support
positive	0.8447	0.8501	0.8474	3763
danger	0.7193	0.7183	0.7188	2322
critical	0.4784	0.4833	0.4808	389
emergency	0.5977	0.4643	0.5226	112
accuracy			0.7754	6586
macro avg	0.6600	0.6290	0.6424	6586
weighted avg	0.7747	0.7754	0.7749	6586

강점:

- Emergency f1 성능 최고
- Critical 성능 5번 대비 향상

약점:

- Danger recall이 5번보다 낮음

8. KcBERT-RiskBalance

[Classification Report]

	precision	recall	f1-score	support
positive	0.8500	0.8403	0.8451	3763
danger	0.7060	0.7394	0.7223	2322
critical	0.5178	0.4499	0.4814	389
emergency	0.5729	0.4911	0.5288	112
accuracy			0.7757	6586
macro avg	0.6617	0.6302	0.6444	6586
weighted avg	0.7749	0.7757	0.7750	6586

강점:

- emergency & critical 최고 성능
- 소수 클래스 특화
=> Critical/Emergency 탐지능력 최고
- Danger Recall 최고

약점:

- Positive 성능 저하:
Precision/Recall 모두 5번보다 낮음
- 다수 클래스 희생:
Positive/Danger 성능 저하

Critical 클래스

지표	1위 모델	2위 모델	3위 모델
Precision	8번(0.5178)	7번 (0.5156)	2번 (0.4879)
Recall	8번(0.4833)	7번 (0.4242)	4번 (0.4306)
F1-Score	8번(0.4814)	7번 (0.4654)	2번 (0.4515)

➡ 8번이 압도적 1위

Emergency 클래스

지표	1위 모델	2위 모델	3위 모델
Precision	6번 (0.8333)	7번 (0.5824)	8번 (0.5729)
Recall	2번 (0.4940)	8번 (0.4911)	5번 (0.4819)
F1-Score	8번 (0.5288)	7번 (0.5222)	1번 (0.4706)

➡ 8번이 가장 균형잡힌 Emergency 성능
(6번은 전체성능 붕괴로 실용성 없음)

**Emergency/Critical이 중요한
긴급상황 모니터링이므로,**

8번 모델 선정

- Emergency F1 0.5288 (1위)
- Critical F1 0.4814 (1위)
- 소수 클래스 탐지 능력 우수
- 모든 클래스에 균형 잡힌 성능

8번 모델 KcBERT-RiskBalance 선정

- KcBERT-base
- 한국어 문맥 이해에 최적화

Fine-tuning 설정

하이퍼파라미터	값
Batch Size	32
Max Length	128
Epochs	5
Learning Rate	2e-5
Weight Decay	0.01
Optimizer	AdamW
Scheduler	Linear+Warmup

위험도 레벨	건수	비율
Positive	18,813	57.13%
Danger	11,610	35.26%
Critical	1,947	5.91%
Emergency	558	1.69%

➡ 데이터 불균형 문제 : Class Weight 적용하여 해결

데이터 처리 전략

- 모든 세트에서 클래스 비율 동일하게 유지
=> 과적합 방지, 공정한 성능평가, 소수클래스 보호

분할 결과	세트	개수	비율
	Train	19,756	60%
	Val	6,586	20%
	Test	6,586	20%

클래스 분포	Dataset	Positive	Danger	Critical	Emergency
	Train	11,287	6,966	1,168	335
		57.1%	35.3%	5.9%	1.7%
	Val	3,763	2,322	390	111
		57.1%	35.3%	5.9%	1.7%
	Test	3,763	2,322	389	112
		57.1%	35.3%	5.9%	1.7%

Class Weight(자동계산)

클래스	가중치
Positive	0.4376
Danger	0.7090
Critical	4.2286
Emergency	14.7433

불균형 데이터 처리

- 소수 클래스(emergency)에 높은 가중치
- 모델이 희귀 클래스에 집중
- 전체적인 성능 향상

Epoch별 성능 변화

Epoch	Train Loss	Train Acc	Val F1
1	1.0939	0.6138	0.7186
2	0.7330	0.7453	0.7424
3	0.4843	0.8167	0.7491
4	0.3156	0.8664	0.7664
5(Best)	0.2095	0.9029	0.7719



- Loss 지속 감소
- Accuracy 지속 증가
- Overfitting 없음

Best model: Epoch 5

최종 성능

- Test Accuracy: 77.6%
- F1 Macro : 0.6444
- F1 Weighted : 0.7750

클래스	Precision	Recall	F1-Score	Support
positive	0.8500	0.8403	0.8451	3,763
danger	0.7060	0.7394	0.7223	2,322
critical	0.5178	0.4499	0.4814	389
emergency	0.5729	0.4911	0.5288	112

입력 테스트	가중치	신뢰도
"오늘 날씨가 좋네요"	positive	99.8%
"우울해요"	danger	71.9%
"죽고 싶어요"	critical	99.9%
"도와줘"	emergency	99.9%

Part 5

Bert-LLM결합 모델



구분	1단계 : BERT 위험도 판단	구분	2단계 : LLM 근거 생성
모델	KcBERT-RiskBalance	모델	Gemma3 (1B, GGUF)
입력	대화 텍스트	입력	BERT 판단 결과 + 원문
출력	4단계 등급 - positive (안정) - danger (주의) - critical (위험) - emergency (긴급)	출력	판단 근거 설명
		기술	LangChain + LangGraph
		특징	AI Agent 구조
		장점	XAI(설명 가능한 AI)

기술적 특징

CPU환경 최적화

- GPU없이 로컬 가정용 CPU 환경에서도 가동 가능


로컬 실행

- 개인정보보호 (외부API 불필요)

실시간 처리

- 대화종료 후 즉시 분석 (10분 단위 구분)

LangGraph AI Agent



시스템 프롬프트

```
# *** 모델 설정 ***
model_path = "./0. src/gemma-3-18-it-QAT-Q4_01.gguf"

raw_llm = ChatLlamaCpp(
    model_path=model_path,
    n_ctx=4096, # 컨텍스트 길이 설정 (길수록 성능 향상)
    n_gpu_layers=35, # GPU 오프로드 레이어 수
    temperature=0.0,
    verbose=False,
)
```

```
first_prompt_str = """
당신은 훌륭한 번역가가 아닙니다. 이미 다른 시스템이 문장과 문장 중간에 문장을 삽입합니다.
당신의 임무는 **원본 문장을 그대로 유지한 채**, 그 이유만 표기하여 설명하는 것입니다.
세로줄로만, 제목줄, 반박, 열거를 해서 안 됩니다.
```

출력 형식(여러 형식을 반드시 그대로 따르십시오):
문장: "text"
판단 근거: (해당 문장이 '{answer}' 등급으로 분류된 이유를 설명.
이유는 반드시 '{answer}'가 맞다는 방향으로 작성해야 하며, 부정하거나 반박하지 마십시오.)

모델결과.xlsx 일부

[illegible]

LLM제어를 최소로 하기위해 온도를 0으로 설정함

감사합니다.

팀 투윤백

Q&A